LAB 2 - manipulate semi-structured JSON - XML data (avec Python).

2CS - ESTIN - 2023 /2024

### 1. Introduction

La transmission d'informations d'une machine à une autre, d'un logiciel à un autre ou d'une base de données à une autre est une tâche récurrente. Le format de données le plus simple est le format CSV. Cela fonctionne bien pour les tableaux mais il ne transmet pas facilement des données non structurées.

Le but de ce TP est de montrer et d'essayer comment manipuler des formats de données non structurés (semi-structurés) avec le langage Python et ses bibliothèques.

## 2. Ensembles de données de laboratoire :

The **Iris** Dataset. Il s'agit peut-être de la base de données la plus connue de la littérature sur la reconnaissance de formes. Cet ensemble de données se compose de 3 types différents de longueur de pétale et de sépale d'iris (Setosa, Versicolour et Virginica), stockés dans un numpy.ndarray de 150x4.

Les lignes sont les échantillons et les colonnes sont : longueur des sépales, largeur des sépales, longueur des pétales et largeur des pétales.

Le tracé ci-dessous utilise les deux premières fonctionnalités. Voir ici pour plus d'informations sur cet ensemble de données.

https://scikit-

learn.org/stable/auto examples/datasets/plot iris dataset.html

#### Question 1:

Téléchargez l'ensemble de données et affichez-en une partie.

#### **Indications pour l'utilisation:**

use sklearn.datasets library

#### Question 2:

Écrire les données au format CSV

#### Indications pour l'utilisation :

use StringIO , to\_csv().

#### Question 3:

Écrire des données au format JSON

### Indications pour l'utilisation :

use StringIO , to\_csv().

# 3. XML vers JSON

**Q4**: écrivez le code Python qui convertit le fichier XML en code de langage JSON.

#### **Indications pour l'utilisation:**

- use xml.etree.ElementTree library
- E.parse(), tree.getroot()..

```
<?xml·version="1.0" encoding="UTF-8</pre>
       <?xml-stylesheet type='text/xsl'?>
10
        <employees>
11
         <details>
           <<firstname>Shiv</firstname>
13
           <lastname>Mishra</lastname>
           <title>Enginner</title>
15
           <division>computer</division>
           <building>301</building>
16
17
            <room>11</room>
         <</details>
18
         <details>
19
         ···<firstname>Yuh</firstname>
20
           <lastname>Datta/lastname>
21
           <title>developer</title>
           <division>computer</division>
23
           <building>303</building>
24
25
            <room>02</room>
         .</details>
26
27
        <details>
           <firstname>Rahil</firstname>
28
29
           <lastname>Khan</lastname>
30
           <title>Tester</title>
31
           <division>computer</division>
32
           <building>304</building>
33
            <room>10</room>
34
         .</details>
        <details>
35
           <firstname>Deep</firstname>
36
37
           <lastname>Paraph</lastname>
           <title>Designer</title>
38
39
           <division>computer</division>
           <building>305</building>
40
            <room>14</room>
         </details>
43
       </employees>
```

## 4. XML vers JSON

**Q5**: écrivez le code Python qui convertit le fichier JSON à côté d'un code de langage XML.

 Indications pour l'utilisation : use json library

## Comparaison between JSON and XML

JSON	XML
JSON object has a type	XML data is typeless
JSON types: string, number, array, Boolean	All XML data should be string
Data is readily accessible as JSON objects	XML data needs to be parsed
JSON is supported by most browsers	Cross-browser XML parsing can be tricky
JSON has no display capabilities	XML offers the capability to display data because it is a
	markup language
JSON supports only text and number data	XML support various data types such as number, text,
type.	images, charts, graphs, etc. It also provides options for
	transferring the structure or format of the data with actual
	data.
Retrieving value is easy	Retrieving value is difficult
Supported by many Ajax toolkit	Not fully supported by Ajax toolkit
A fully automated way of	Developers have to write JavaScript code to serialize/de-
deserializing/serializing JavaScript	serialize from XML
Native support for object	The object has to be express by conventions – mostly missed
	use of attributes and elements.
It supports only UTF-8 encoding.	It supports various encoding
It doesn't support comments.	It supports comments.
JSON files are easy to read as compared to	XML documents are relatively more difficult to read and
XML.	interpret.
It does not provide any support for	It supports namespaces.
namespaces	
It is less secured.	It is more secure than JSON.